

분석 단계 보고서

목차

1. 서론
 - 1-1 프로젝트 배경 및 문제 정의
 - 1-2 분석의 궁극적 목표
2. 본론
 - 2-1 데이터 수집과 전처리
 - 2-2 분석 방법론
3. 결론
 - 3-1 향후 시각화 계획

1. 서론

1-1) 프로젝트 배경 및 문제 정의

서울시 대중교통 이용객이 증가함에 따라 단순한 노선 확충을 넘어, 공급의 불균형과 비합리성을 파악하는 것이 이 프로젝트의 중점입니다. 본 프로젝트는 서울시 공공데이터를 활용하여 행정동별 인구수(수요)와 정류장(공급) 데이터 간의 차이를 데이터에 기반하여 입증하고자 합니다.

1-2) 분석의 궁극적 목표

단순히 정류장이 적다는 것이 소외를 의미하지는 않습니다. 인구 대비 정류장이 부족한 실질적 교통 소외지역을 조명하고, 주중/주말 이동 패턴 분석을 통해 행동의 성격(주거/업무/상업,문화)을 규명하는 것이 중요합니다.

2. 본론

2-1) 데이터 수집 및 전처리

- 데이터셋 구조 및 아카이빙 전략 분석을 위해 BusDataHistory(Cold Data) 모델을 활용하여 과거 1개월(혹은 그 이상) 치의 승하차 이력을 불러옵니다. Busstop_id를 키로 사용하여 BusStop 모델의 district_id(행정동)와 매핑함으로써 공간 정보를 결합합니다.
- 결측치 보정 및 신뢰도 확보를 위해 외부 API 특성상 간헐적인 데이터 누락이 발생합니다. 단순히 총합을 사용할 경우 데이터 수집 일수에 따라 왜곡이 발생할 수 있으므로, 일평균 승하차 인원을 기준으로 정규화합니다. Django ORM의 Avg 함수를 활용하여 Null 값을 자동으로 제외하고 평균을 산출합니다. 또한, 분석의 신뢰도를 위해 주중 3일, 주말 2일 이상 데이터가 확보된 행정동만을 분석 대상에 포함합니다.
- 파생 변수(Tagging)를 설정해서 수집된 timestamp를 기준으로 요일(월-일)을 가져와 주중과 주말로 데이터를 태깅하고 그룹화합니다.
 - ➔ 우리가 수집한 BusDataHistory 데이터는 2025-10-25 같은 날짜만 들어가 있다. 이걸 컴퓨터는 날짜만보고 이걸 토요일이라서 사람들이 놀러 많이 갔겠구나라고 스스로 판단하지 못함. 따라서 코드로 규칙을 정해줘야 함. 날짜를 확인해서 토요일, 일요일이면 주말이라는 이름표를 붙이고 월-금이면 주중이라는 이름표를 붙여야한다. 따라서 원본 데이터의 timestamp 필드는 날짜 정보만을 포함하고 있어, 생활 패턴 분석에 필요한 요일별 특성을 반영하지 못한다. 날짜 데이터를 기반으로 요일 속성을 추출하려면 주중,주말이라는 범주형 변수로 변환하여 분석해야한다.

2-2) 분석 방법론

- [거시적 관점] 수요와 공급의 상관관계 분석(Pearson r) 서울시 전체의 버스 행정 건전성을 평가하기 위해 행정동 인구수(X)와 정류장수(Y) 간의 피어슨 상관계수 r를 산출합니다.
- SciPy 활용: `scipy.stats.pearsonr(x,y)`
- r 값이 0.7 이상이면 인구 비례에 맞춰 설계된 것이며, 0.5 이하일 경우 수요-공급 불균형이 있다 혹은 심각함을 시사합니다.
- [미시적 관점] 회귀 분석을 통한 교통 소외 지역 도출: 전체적인 추세선($y=a*x+b$)을 기준으로 개별 행정동의 특이성을 파악합니다. 이를 위해 실제 정류장 수와 예측된 정류장 수의 차이인 잔차를 분석합니다.
 - ➔ 독립변수(X): 행정동별 인구 수(수요), 종속변수(Y): 행정동별 버스 정류장 수(공급)
 - ➔ 상수 설정(a,b): 컴퓨터가 전체 데이터를 보고 가장 오차가 적은 최적의 값을 계산해준다.
 - 기울기(a): 인구 1 명이 늘어날 때 정류장이 몇 개나 늘어나는가?(서울시 평균 비율)
 - 절편(b): 인구가 0 명이어도 기본적으로 존재하는 정류장 개수(기본 인프라)
 - ➔ `Scipy.stats.linregress(x,y)` 함수로 이 함수가 서울시 400 여 개 동 데이터를 싹 훑어보고 서울시에는 보통 인구 1000 명당 정류장 0.5 개가 있는게 표준이네 하고 a와 b의 값을 반환해준다.
 - ➔ 잔차= 실제값-예측값
 - ➔ 예측값 계산: 예) 흑석동 인구가 30000 명일 때 서울시 표준대로라면 정류장이 몇 개 있어야 하는지 계산한다.(a와 b는 임의의 수입니다.)
 $Y=0.001*30,000 + 5 = 35$ 개(예측)
 - ➔ 실제값 확인: 예) b=25
 - ➔ 잔차 계산: $25-35=-10$
- 잔차>0 : 예측보다 정류장이 많음 -> 과잉 공급 또는 유동인구가 많은 환승 거점/상업 지구.
- 잔차<0: 예측보다 정류장이 부족함 -> 교통 소외 지역으로 정의하고 집중 조명
- [심층분석] 단순 인구수로는 알 수 없는 도시의 맥락을 파악하기 위해 주말 집중도(Weekend Intensity Index)를 고안했습니다.
Index 공식: 주말 일평균 승하차 인원/주중 일평균 승하차 인원

업무지구(index <0.7): 주중에 집중되고 주말에 공동화 현상 발생(예: 여의도, 강남)

주거지구(0.7<=Index<=1.2): 요일별 유동 인구 변화가 미비함

문화/상업지구(Index>1.2) 주말 외부 유입이 주중보다 많음(예: 성수, 홍대)

- 통계적 검증(T-test) 주중/주말 평균의 차이가 우연에 의한 것이 아님을 증명하기 위해 T-test 를 수행하며 p-value < 0.05 인 경우엔 해당 분류를 유효한 것으로 채택한다.
- [효율성 분석] 정류장 혼잡도 분석: 총 승하차 인원/정류장 개수를 통해 정류장의 운영 효율성을 진단합니다. 혼잡도가 지나치게 높은 곳은 시설 확충이 필요하며, 낮은 곳은 비효율적 운영으로 판단합니다.

3. 결론

3-1) 향후 구현 계획: 데이터 시각화(제미나이 제공)

4.1 거시적 시각화: 인터랙티브 코로플레스 지도 (Choropleth Map)

- **개요:** 웹 서비스 메인 화면에 위치하며, 사용자의 필터 선택에 따라 행정동의 색상이 변화합니다 ¹⁹.
- **View 1 (도시 성격):** 업무(파랑), 문화(빨강), 주거(초록), 데이터 부족(회색)으로 지구의 성격을 색상 코딩합니다 ²⁰.
- **View 2 (소외 레벨):** 회귀 분석 잔차 값에 따라 '진한 보라색(소외)'에서 '진한 초록색(과잉)'으로 이어지는 Diverging Color Scale 을 적용하여 형평성을 시각화합니다 ²¹.

4.2 분석적 시각화: 동적 산점도 (Interactive Scatter Plot)

- **개요:** 통계 대시보드 페이지의 핵심 차트로, 분류 로직의 타당성을 시각적으로 검증합니다 ²².
- **구현:** X 축은 주중 인원(Log), Y 축은 주말 인원(Log)으로 설정하고 $y=x$ 대각선을 기준선으로 배치합니다. 기준선 아래는 업무 지구, 위는 문화 지구로 나뉘는 분포를 한눈에 보여줍니다 ²³.
- **기능:** D3.js 의 enter/update 패턴을 활용해 결측치가 있는 데이터는 제외하고, 툴팁을 통해 상세 수치를 제공합니다 ²⁴²⁴²⁴.

4.3 미시적 시각화: 시계열 비교 차트 (Multi-Line Chart)

- **개요:** 특정 행정동 상세 페이지에서 제공되는 차트입니다 ²⁵.

- **구현:** 하나의 그래프에 '주중 추세선'과 '주말 추세선'을 겹쳐 그립니다 ²⁶.
- **스토리텔링:** 사용자가 업무 지구(여의도 등)를 선택했을 때 주중 선은 높고 주말 선은 낮아지는 극적인 패턴 차이를 눈으로 확인하게 하여 분석 결과를 직관적으로 납득시킵니다 ²⁷.